

全台房價季度預測模型



1. 專案概述


目標：建立一套可重複執行、每季更新的全台房價預測與中位數估算系統

資料來源：內政部實價登錄資料庫（2012-2026 Q1，共 57 季，逾 100 萬筆資料）

核心產出：各縣市/行政區每季房價中位數、SHAP 特徵重要性排名



2. 資料流程圖 Pipeline



3. 資料清洗 Data Cleaning

原始資料包含大量非市場常規交易，若不清洗會嚴重干擾房價中位數的估算。清洗分四個步驟：

1. 排除非常規交易（備註關鍵字過濾）

過濾備註欄位含以下關鍵字的資料：親友、員工、共有人、特殊、二親等、瑕疵、事故、法拍、地下室、關係人、持分。這類交易的成交價格受人際關係或法律狀態影響，無法反映市場行情。

2. 排除非住宅類型

排除土地、車位、廠辦、辦公商業大樓、透天厝及其他特殊類型，將分析範圍限定於一般住宅（公寓／電梯大樓），確保模型學習目標一致。

3. 排除一樓交易

一樓物件常混有商業用途（店面、診所等），定價邏輯與一般住宅樓層顯著不同，納入會引入系統性雜訊。

4. IQR 離群值清洗

以各行政區為單位，計算坪單價的 Q1 與 Q3，刪除落在 $[Q1 - 1.5 \times IQR, Q3 + 1.5 \times IQR]$ 範圍外的資料。採行政區分層處理而非全台統一門檻，是因為台北市與偏鄉的房價尺度差異極大，統一門檻會誤刪偏鄉正常交易或保留都市異常值。



4. 特徵工程 Feature Engineering

目標變數

- unit_price_ping：**將每平方公尺單價換算為坪單價後取 log，壓縮右偏分布、使殘差更接近常態，提升模型穩定性

房屋本體特徵

- **building_age**：以交易年份減建造年份計算屋齡，比直接使用建造年份更能反映「當下折舊狀態」，且跨季資料不需重新編碼
- **floor_numeric**：將樓層文字（如「三樓」）轉為數值，使模型可捕捉樓層與房價的單調關係
- **log_total_area**：總面積取 log，處理大坪數物件造成的右偏問題，並捕捉坪數對單價的邊際遞減效應

地段價值特徵

- **district_mean**：各行政區的房價平均數，作為區域基準價格的代理變數
- **cluster_id_mean**：單純的行政區均價過於粗糙，同一行政區內地段差異顯著。以經緯度對全台資料做 K-means 空間聚類，計算各群組房價均值，捕捉比行政區更細緻的局部地段溢價
- **road_volume**：從地址提取路名，統計各路段的歷史交易量，作為路段熱門程度與曝光度的指標
- **dist_shop_m**：利用公開資料取得全台主要商圈地址並轉換座標，計算每筆房屋與最近商圈的距離（公尺），捕捉生活機能對房價的影響
- **dist_to_mrt / dist_to_tra / dist_to_hsr**：分別計算與最近捷運站、台鐵站、高鐵站的直線距離，量化三種交通網絡對房價的可及性溢價


類別特徵編碼

- **district**、**house_type** 設為 `category` dtype，直接傳入 LightGBM 原生類別特徵處理，讓模型自動學習最佳分組方式

5. 探索性分析 EDA

屋齡與單價交互作用觀察

- 變數間交互作用：屋齡對房價的影響力，會隨著行政區的不同而改變




變數線性(紅)/非線性(綠)關係圖

- 屋齡與單價的非線性關係：從 `building_age` 對應 `unit_price_ping` 的圖表可發現屋齡對房價的影響並非等比例下降，可能在屋齡極高時（老屋翻新或改建價值）趨勢會產生轉折。

- 交通距離的閾值效應：觀察 `dist_to_mrt_m`（距捷運站距離）與單價的關係，綠線在距離極近時呈現陡峭下降，隨後趨於平緩。這證明了捷運效應具有明顯的「距離門檻」，線性模型（紅線）無法精準捕捉這種「近捷運極貴、遠捷運影響力鈍化」的特性。

台北市全變數關係診斷圖：線性(紅) vs 非線性(綠)



⚙️ 6. 建模 Modeling

模型選擇：LightGBM

EDA 發現房價與多個特徵之間存在顯著非線性關係（如屋齡的 U 型效應），線性模型無法有效捕捉，因此採用梯度提升樹架構。

最終選擇 LightGBM，原因如下：

- **速度**：Histogram-based 分裂演算法，處理百萬筆資料仍保持高效
- **類別特徵**：原生支援 `category` dtype，無需 One-hot encoding，自動學習最佳分組
- **缺失值**：自動處理缺失值，不需額外填補策略
- **交互作用**：Leaf-wise 生長策略，能捕捉特徵間複雜的交互效應（如「屋齡對房價的影響因行政區而異」）

驗證策略：10-Fold Cross Validation

將資料切成 10 份，每次以 9 份訓練、1 份測試，輪流進行十次，確保每筆資料都會作為測試集。相較於單次 train/test split，10-fold 的評估結果對資料分割方式的依賴性更低，指標更具代表性。

評估指標


指標	用途
R²	衡量模型對房價變異的整體解釋能力
MAE	以原始坪單價尺度呈現平均預測誤差
RMSLE	因目標變數 y 已取 log，RMSLE 衡量相對誤差，對高價物件的過度懲罰較不敏感，更符合房價預測的評估需求



7. 模型解釋 SHAP

SHAP 將每個特徵對每筆預測的貢獻量化為可加性數值，使「黑盒模型」的預測依據得以解釋。

以新北市 2025 Q3 模型的 SHAP Summary Plot 為例，特徵重要性排序如下：



排名	特徵	解讀
1	cluster_id_mean	最重要特徵。局部空間聚類均價的預測力超過行政區層級，驗證了「同一行政區內地段差異顯著」的假設
2	building_age	新成屋溢價明顯
3	log_total_area	坪數取 log 後與單價呈負相關，反映大坪數物件的單價邊際遞減現象
4	house_type	房屋類型（電梯大樓 vs 公寓等）對定價有系統性影響，LightGBM 透過原生類別處理有效捕捉
5	district_mean	行政區均價作為區域基準仍有貢獻，但重要性低於局部聚類均價，與設計預期一致
6	dist_to_mrt	捷運距離對房價的影響呈現閾值效應——500 公尺內溢價顯著，超過後影響力趨緩

設計驗證：`cluster_id_mean` 重要性排名第一、高於 `district_mean`，印證了「K-means 空間聚類比行政區分類更能捕捉局部地段溢價」的特徵設計假設。



8. 結果 Output

後處理：排除極端誤差樣本

模型預測誤差最大的 10% 樣本，通常來自資料本身的雜訊（特殊成交條件、地址填寫錯誤、罕見物件類型），這類樣本的預測值偏離真實值的原因不具代表性。排除後再計算統計指標，能使結果更貼近市場真實行情。

產出結構

以保留樣本為基礎，依下列三個維度交叉分群，計算各群的房價統計指標（min、Q1、Q2、Q3、max、mean），並寫入資料庫：

分群維度	說明
行政區	全台各縣市行政區
屋齡區間	例如 0-5 年、5-10 年、10-15 年、30 年以上
房屋類型	電梯大樓、公寓等

這使得最終產出不只是「一個全台平均數」，而是一個可依條件查詢的房價分佈資料庫，能回答「新北市板橋區、屋齡 10 年內、電梯大樓的市場中位數是多少」這類具體問題。

模型評估結果（六都，2025 Q3）

- 全台六都模型之平均 R^2 穩定維持在 0.75 - 0.84 之間。其中新北市與高雄市的表現最為突出，兩者皆具備資料量龐大、行政區多元的特性，提供模型足夠的樣本學習各類地段與房型的價格規律，泛化能力因此較強。
- 平均 RMSLE 穩定控制在 0.13 - 0.16 之區間。由於目標變數經過 Log 轉換，較低的 RMSLE 代表模型對不同價位物件的相對預測誤差一致，無論是偏鄉平價住宅還是都市高價物件，預測偏差的比例都受到同等控制，不會因為絕對金額落差而失真。

	預測房價平均數 (2025Q3)	樣本數	平均 R^2	平均 MAE (元/ 坪)	平均 RMSLE	排除後樣本數
台北市	842646 元/坪	2814	0.7950	84985.8916	0.1325	1885
新北市	486561 元/坪	5223	0.8410	47468.3075	0.1455	3687
桃園市	308325 元/坪	3288	0.8131	30016.3101	0.1375	1989
台中市	307339 元/坪	3327	0.7563	31176.6802	0.1379	1944
台南市	259122 元/坪	1869	0.7532	28006.9097	0.1665	808
高雄市	288568 元/坪	3413	0.8333	27792.5656	0.1645	1922

應用串接

統計結果寫入公司資料庫，作為前端房價查詢功能的資料來源，將上線於公司官網。使用者可依縣市／行政區／屋齡區間／房屋類型篩選條件，查詢對應的市場房價分佈（Q1／中位數／Q3）。這使本專案從單次分析升級為**每季可更新的房價資訊系統**，具備直接的產品落地價值。



9. 技術棧 Tech Stack

類別	工具
語言	Python
資料處理	Pandas, NumPy
空間分析	GeoPy
建模	LightGBM, scikit-learn
可解釋性	SHAP
視覺化	Matplotlib, Seaborn, Plotly
資料庫	MySQL

10. 挑戰與學到的事 Challenges & Learnings

1. 地理特徵的從零建立

- **挑戰**：原始資料庫僅有文字地址，缺乏任何空間資訊，無法直接反映捷運站、商圈等地標對房價的影響。
- **解決**：串接捷運站、台鐵、高鐵及商圈的開放資料，以 Geopy Haversine 計算每筆物件與最近節點的直線距離，將地段可及性量化為數值特徵。SHAP 結果顯示 `dist_to_mrt` 進入前六大重要特徵，驗證此設計有效捕捉了交通溢價。

2. 行政區均價不夠細緻

- **挑戰**：同一行政區內的地段差異極大（如板橋江子翠與新埔的房價差距），單純用行政區均價作為地段特徵過於粗糙。
- **解決**：以經緯度對全台資料做 K-means 空間聚類，計算各群組房價均值作為更細緻的地段代理變數。SHAP 結果中 `cluster_id_mean` 重要性排名第一且高於 `district_mean`，直接驗證了這個設計假設。

3. 極端誤差樣本對統計指標的干擾

- **挑戰**：即使經過初步清洗，仍有少數極端樣本（地址填寫錯誤、罕見物件類型）會拉偏季度房價中位數，影響產出指標的市場代表性。
- **解決**：建立後處理機制，以殘差分析剔除預測誤差最大的前 10%，使最終寫入資料庫的統計指標更穩定，也讓前端查詢結果更貼近真實市場行情。

4. 跨縣市離群值門檻的設計

- **挑戰**：若以全台統一 IQR 門檻清洗離群值，會誤刪偏鄉的正常交易（因為基準價格遠低於都會區），或保留都市的異常高價。
- **解決**：改以各行政區為單位分別計算 IQR，確保每個區域的清洗門檻符合當地市場尺度。